

智能Agent测试分析报告（含实测数据）

一、测试概述

1.1 测试目的

本次测试针对自研智能问答Agent（通用业务交互型）进行全维度能力校验，通过标准化测试用例、压力测试、场景化实测，精准验证Agent的**问答准确率、响应性能、稳定性、容错性、多轮对话连贯性**核心指标，定位现有功能缺陷、性能瓶颈及体验问题，为Agent迭代优化、上线落地、业务适配提供数据支撑。

1.2 测试对象

测试主体：通用业务智能Agent V1.0

核心能力：日常问答、业务咨询、多轮上下文对话、简单指令执行、异常问题容错、知识库匹配应答

1.3 测试范围

覆盖功能测试、性能测试、稳定性测试、准确率测试、异常场景测试5大维度，共计800条有效测试用例，涵盖通用场景、业务场景、边界场景、异常场景四大类。

1.4 测试环境

环境类型	配置参数
服务器配置	8核16G CPU、512G SSD、千兆带宽
系统环境	CentOS 7.9、Python 3.9、模型推理框架V2.1
知识库版本	通用+业务专属知识库V1.0 (共计2.3万条知识条目)
测试工具	JMeter（压力测试）、自研Agent测试平台（自动化用例执行）、人工核验工具
测试时间	2026年06月01日-2026年06月03日

二、测试用例及数据统计

2.1 用例分布情况

测试场景分类	用例数量	用例占比	测试方式
通用日常问答	300	37.5%	自动化+人工核验
专属业务问答	250	31.25%	自动化+人工核验
多轮上下文对话	150	18.75%	人工+自动化联动测试
异常/边界场景	100	12.5%	专项自动化测试
合计	800	100%	-

2.2 整体测试结果汇总

本次测试共执行800条用例，有效用例800条，无无效、废弃用例。整体通过率92.25%，未通过用例62条，整体性能、稳定性达标，准确率存在小幅优化空间。

指标项	目标值	实测值	达标情况
整体用例通过率	≥90%	92.25%	达标
问答准确率	≥91%	90.12%	接近达标（轻微不达标）
平均响应耗时	≤1.5s	1.21s	达标
高并发稳定性（100并发/30min）	无报错、无超时	0报错、0超时	达标
异常场景容错率	≥95%	96.8%	达标

三、分维度详细测试数据及分析

3.1 准确率测试数据分析

准确率定义：Agent应答内容准确、贴合用户问题、无错误信息、无答非所问，即为有效准确应答，由人工+算法双重核验判定。

场景分类	测试用例数	准确应答数	准确率	问题核心原因
------	-------	-------	-----	--------

通用日常问答	300	294	98.00%	极少口语化歧义问题解析偏差
专属业务问答	250	228	91.20%	新增业务知识点未录入知识库、相似业务问题混淆
多轮上下文对话	150	126	84.00%	多轮对话上下文遗忘、指代解析错误
异常/边界场景	100	97	97.00%	极低概率乱码输入应答冗余

分析结论：Agent通用场景能力成熟度最高，异常场景容错能力良好；短板集中在**多轮上下文对话**和**新增业务问答**，是后续迭代核心优化方向。

3.2 性能测试数据分析

通过JMeter模拟不同并发量级，测试Agent单条请求响应耗时、吞吐量、超时率，测试时长每组30分钟，数据取平均值。

并发量级	平均响应耗时	最大响应耗时	吞吐量（次/分钟）	请求超时率
20并发（日常低峰）	0.68s	1.02s	1180	0%
50并发（日常高峰）	0.95s	1.36s	2890	0%
100并发（压力场景）	1.21s	1.89s	5620	0.12%
150并发（极限场景）	1.76s	2.53s	7950	0.85%

分析结论：日常业务高峰（50并发）下性能表现优秀，完全满足业务需求；100并发存在极少量超时，150极限并发下响应耗时超标，高并发场景存在性能瓶颈，需优化推理效率。

3.3 稳定性测试数据分析

持续24小时不间断循环执行测试用例，累计执行请求12.8万次，统计服务报错、宕机、重启、内存溢出等异常情况。

测试时长	总请求数	服务报错次数	服务宕机次数	内存溢出情况	服务稳定性

24h持续测试	128000	36	0	无	99.97%稳定率
---------	--------	----	---	---	-----------

异常报错明细：36次报错均为网络瞬时波动导致的请求重试失败，无Agent程序本身BUG、无服务崩溃，整体稳定性满足线上运行标准。

3.4 异常场景测试数据分析

针对空白输入、乱码输入、超长文本、无意义提问、跨领域冷门问题等100条边界用例进行测试，统计容错处理能力。

异常类型	用例数	合理容错处理数	容错率
空白/空输入	20	20	100%
乱码/特殊符号输入	25	24	96%
超长文本（>500字）	20	19	95%
无意义冷门提问	35	33	94.2%

分析结论：Agent对常规异常输入拦截、提示能力完善，仅在复杂乱码、超长冗余文本场景存在少量应答冗余问题，容错能力整体达标。

四、现存问题汇总（基于测试数据）

4.1 准确率类问题

- 1. 多轮上下文对话能力薄弱，150条用例中24条出现上下文遗忘、指代解析错误，是准确率偏低的核心原因；
- 2. 知识库覆盖不全，新增业务知识点未录入，导致22条业务问答应答错误；
- 3. 对口语化歧义问题的语义解析精准度不足，通用场景存在少量答非所问情况。

4.2 性能类问题

- 1. 超高并发（150并发）场景下，平均响应耗时突破2s，超出标准阈值；
- 2. 高压场景下存在0.85%的请求超时率，大流量场景适配能力不足。

4.3 体验类问题

- 1. 复杂乱码、超长文本输入时，应答内容存在冗余、无效信息；
- 2. 部分相似业务问题区分度不足，应答内容同质化严重，针对性较弱。

五、优化建议及迭代方案

5.1 准确率优化

- 1. 优化多轮对话上下文记忆机制，增强指代消解、上下文关联解析能力，预计将多轮对话准确率提升至92%以上；
- 2. 补充更新业务知识库，录入新增业务知识点、细化相似业务问题区分规则；
- 3. 微调语义解析模型，强化口语化、歧义语句的识别能力。

5.2 性能优化

- 1. 优化模型推理算法，精简冗余计算，降低高并发场景响应耗时；
- 2. 增加请求限流、缓存机制，提升大流量场景吞吐量，降低超时率；
- 3. 针对峰值场景做资源扩容适配，保障150并发内响应耗时 $\leq 1.5s$ 、超时率 $\leq 0.1\%$ 。

5.3 体验及容错优化

- 1. 新增超长文本、乱码输入过滤清洗规则，自动剔除无效输入，精简应答内容；
- 2. 优化相似问题应答模板，提升业务问答的针对性和精准度。

六、测试总结

本次对智能Agent V1.0的全维度测试数据表明，该版本Agent**整体能力达标、稳定性优秀、容错能力良好**，能够满足日常常规业务交互需求。核心短板集中在多轮对话准确率、超高并发性能、业务知识库覆盖三个方面，无致命BUG、无服务崩溃等严重问题。

经过后续针对性迭代优化后，可全面满足线上正式环境的高可用、高精度、高响应的业务要求，具备上线迭代条件。

七、附件

- 1. 完整测试用例清单（800条）
- 2. 性能测试原始日志、稳定性测试数据报表
- 3. 问题BUG明细及复现步骤文档

（注：文档部分内容可能由 AI 生成）